

Proiect Inteligență Artificială

Raport – Parkinson (Perceptron Multi-Strat – MLP)

1. Introducere

Scopul principal al proiectului este de a face distincția între persoanele sănătoase și cele cu boala Parkinson în funcție de caracteristicile audio înregistrate. Așadar problema abordată este una de clasificare binară:

- 1 = bolnav
- 0 = sănătos

2. Baza de date

Baza de date „Parkinsons” este formată din măsurătorile vocale de la 31 de persoane, dintre care 23 au boala Parkinson. Aceasta conține 195 de linii (instanțe), fiecare linie conținând la rândul ei câte 22 de atribute (caracteristicile audio înregistrate) și eticheta (status) care arată dacă o persoană este bolnavă sau nu. Baza de date a fost preluată de pe site-ul UC Irvine Machine Repository: <https://archive.ics.uci.edu/dataset/174/parkinsons>

3. Librării utilizate

- Pandas – pentru prelucrarea și extragerea datelor sub formă de DataFrames
- Scikit Learn (sklearn):
 - sklearn.model_selection – pentru împărțirea datelor în seturi de antrenament și testare (train_test_split);
 - sklearn.preprocessing – pentru normalizarea datelor (StandardScaler);
 - sklearn.neural_network – pentru antrenarea modelului de rețea neurală (MLPClassifier);
 - sklearn.metrics – pentru evaluarea performanței modelului antrenat (accuracy_score, classification_report, confusion_matrix)

4. Împărțirea datelor între train și test

Pentru antrenarea și evaluarea modelului MLP, setul de date a fost împărțit 75% într-un set de antrenament (146 de linii) și 25% într-un set de testare (49 de linii).

5. Metrica utilizată

Pentru evaluarea performanței modelului am folosit:

- **accuracy score** reprezintă procentul de predicții corecte în raport cu totalul predicțiilor efectuate
- **confusion matrix** arată numărul de instanțe care au fost corect sau greșit clasificate în fiecare categorie (TP = true positives, respectiv TN = true negatives - instanțe clasificate corect aflate pe diagonala principală; FP = false positives, respectiv FN = false negatives – instanțe clasificate greșit aflate pe diagonala secundară)
- **classification report** cuprinde
 - precision = proporția de instanțe prezise corect ca aparținând unei clase, comparativ cu totalul instanțelor prezise ca aparținând acelei clase = $TP/(TP+FP)$;
 - recall = proporția de instanțe corect identificate de model, comparativ cu instanțele care sunt de fapt din acea clasă = $TP/(TP+FN)$;
 - f1-score = media armonică între precision și recall;
 - support = numărul de instanțe din fiecare clasă din setul de date

6. Variația hiperparametrilor

Am testat toate combinațiile posibile (un total de 24 de combinații) între următorii parametri:

- Numărul de straturi ascunse: 1 sau 2 (influențează complexitatea modelului)
- Numărul de neuroni pe straturile ascunse: egal cu stratul anterior, jumătate sau dublu față de cel anterior (influențează capacitatea și costul computațional)
- Learning rate: 0.1 sau 0.01 (influențează viteza de învățare și stabilitatea antrenării)

7. Rezultate

În urma varierii hiperparametrilor am obținut următoarele valori:

Summary of all configurations:		
	Configuration	Accuracy
5	Hidden Layers: (44,), Learning Rate: 0.01	0.959184
21	Hidden Layers: (44, 44), Learning Rate: 0.01	0.959184
3	Hidden Layers: (22,), Learning Rate: 0.01	0.938776
1	Hidden Layers: (11,), Learning Rate: 0.01	0.938776
9	Hidden Layers: (11, 11), Learning Rate: 0.01	0.938776
10	Hidden Layers: (11, 22), Learning Rate: 0.1	0.938776
8	Hidden Layers: (11, 11), Learning Rate: 0.1	0.938776
15	Hidden Layers: (22, 22), Learning Rate: 0.01	0.938776
20	Hidden Layers: (44, 44), Learning Rate: 0.1	0.918367
19	Hidden Layers: (44, 22), Learning Rate: 0.01	0.918367
17	Hidden Layers: (22, 44), Learning Rate: 0.01	0.918367
12	Hidden Layers: (22, 11), Learning Rate: 0.1	0.918367
13	Hidden Layers: (22, 11), Learning Rate: 0.01	0.918367
7	Hidden Layers: (11, 5), Learning Rate: 0.01	0.897959
22	Hidden Layers: (44, 88), Learning Rate: 0.1	0.897959
16	Hidden Layers: (22, 44), Learning Rate: 0.1	0.897959
23	Hidden Layers: (44, 88), Learning Rate: 0.01	0.897959
11	Hidden Layers: (11, 22), Learning Rate: 0.01	0.877551
0	Hidden Layers: (11,), Learning Rate: 0.1	0.877551
2	Hidden Layers: (22,), Learning Rate: 0.1	0.877551
18	Hidden Layers: (44, 22), Learning Rate: 0.1	0.877551
4	Hidden Layers: (44,), Learning Rate: 0.1	0.857143
6	Hidden Layers: (11, 5), Learning Rate: 0.1	0.857143
14	Hidden Layers: (22, 22), Learning Rate: 0.1	0.816327

Se poate observa că cea mai bună acuratețe (96%) a fost obținută în cazurile cu 1 strat ascuns, 44 de neuroni pe strat și learning rate 0.01, respectiv pentru 2 straturi ascunse, 44 de neuroni pe fiecare strat și learning rate 0.01.

Configuration 5: Hidden Layers: (44,), Learning Rate: 0.01				
Accuracy Score: 0.9592				
Classification Report:				
	precision	recall	f1-score	support
0	1.00	0.82	0.90	11
1	0.95	1.00	0.97	38
accuracy			0.96	49
macro avg	0.97	0.91	0.94	49
weighted avg	0.96	0.96	0.96	49
Confusion Matrix:				
[[9 2]				
[0 38]]				

Configuration 21: Hidden Layers: (44, 44), Learning Rate: 0.01				
Accuracy Score: 0.9592				
Classification Report:				
	precision	recall	f1-score	support
0	1.00	0.82	0.90	11
1	0.95	1.00	0.97	38
accuracy			0.96	49
macro avg	0.97	0.91	0.94	49
weighted avg	0.96	0.96	0.96	49
Confusion Matrix:				
[[9 2]				
[0 38]]				